

# Arithmetic Answer Generation with Character-level Sequence Models (LSTM/GRU/Seq2Seq)

## 一、研究概述

本專案將「數學算式到答案」視為序列生成問題：輸入為字元序列（例如  $12+34=$ ），模型需要在  $=$  後逐字生成答案並停止（遇到  $\langle \text{eos} \rangle$ ）。核心模型採用 2-layer LSTM，並以 Exact Match accuracy 評估。同時設計多組實驗，去做結果比較與討論：

- A. LSTM vs GRU 訓練模型的差異性分析
- B. 訓練/驗證分佈不一致（兩位數 vs 混入三位數）
- C. 訓練資料含 20% 錯誤答案 (label noise)
- D. 是否使用 gradient clipping (訓練穩定性)
- E. Seq2Seq Encoder-Decoder + input reversal

## 二、研究流程

### 1. Arithmetic dataset 介紹

使用 Arithmetic dataset 作為資料來源，資料已切分為訓練集(23692501 筆) 與驗證集 (263250 筆)。

## 2. 模型訓練超參數設定

baseline 採用 **2-layer LSTM**，並使用 `CrossEntropyLoss(ignore_index=<pad>)` 作

為損失函數。訓練超參數如下：

- **batch\_size = 64**
- **epochs = 10**
- **embed\_dim = 256**（每個字元以 256 維向量表示）
- **hidden\_dim = 256**（LSTM 隱藏層維度 256）
- **optimizer = Adam**
- **learning\_rate = 0.001**
- **grad\_clip = 1**（最大梯度 1，避免梯度爆炸）

## 3. 實驗組別設計

### (A) LSTM vs GRU（模型結構對照）

在相同超參數下，比較 LSTM 與 GRU 的生成表現與收斂穩定性。

### (B) Distribution Shift：訓練含三位數、驗證只含兩位數

檢驗訓練/驗證資料分佈不一致時的泛化能力下降幅度。

### (C) Label Noise：訓練資料含 20% 錯誤答案

檢驗 teacher forcing 在標註噪音下對學習與最終準確率的影響。

### (D) Ablation：不使用 Gradient Clipping

移除 grad\_clip，觀察 loss 是否暴衝與整體收斂穩定性變化。

### (E) Seq2Seq Encoder–Decoder + Input Reversal

額外實作 Encoder–Decoder 架構並翻轉輸入序列，觀察此技巧在算式任務的適用性。

## 三、結果討論

### A. LSTM vs GRU

| Epoch | LSTM          |                     | GRU           |                     |
|-------|---------------|---------------------|---------------|---------------------|
|       | Training Loss | Validation Accuracy | Training Loss | Validation Accuracy |
| 1     | 0.335         | 0.5793              | 0.459         | 0.5336              |
| 2     | 0.228         | 0.7046              | 0.295         | 0.5736              |
| 3     | 0.166         | 0.7002              | 0.297         | 0.6016              |
| 4     | 0.220         | 0.7997              | 0.289         | 0.6284              |
| 5     | 0.174         | 0.8164              | 0.243         | 0.6587              |
| 6     | 0.135         | 0.7697              | 0.167         | 0.6725              |
| 7     | 0.106         | 0.8652              | 0.314         | 0.6927              |
| 8     | 0.102         | 0.8839              | 0.228         | 0.6864              |
| 9     | 0.103         | 0.8662              | 0.145         | 0.7260              |
| 10    | 0.0689        | <b>0.8927</b>       | 0.0965        | <b>0.7366</b>       |

分析結果說明：

LSTM 記憶單元更完整，較能維持長距離依賴，所以在生成任務更穩定，而

GRU gate 較簡化，表現與收斂穩定度較差（loss 波動較大）。在運算時間上，雖然 GRU 的參數較少、理論上訓練速度應更快，但從實驗實作來看，兩者在訓練時間上差異不大。

## B. Distribution Shift：訓練含三位數、驗證只含兩位數

**Two-digit + three-digit numbers** 訓練資料是額外自行產生，共有 **2325839** 筆樣本，分為三種類型：

- (1) 兩位數 (9.10%)：所有運算元皆為兩位數 (10–99)
- (2) 三位數 (48.51%)：至少一個運算元為三位數 (100–999)
- (3) 混合型 (42.40%)：同時包含兩位與三位數，或包含括號運算式

| Epoch | Only two-digit numbers |                     | Two-digit + three-digit numbers |                     |
|-------|------------------------|---------------------|---------------------------------|---------------------|
|       | Training Loss          | Validation Accuracy | Training Loss                   | Validation Accuracy |
| 1     | 0.335                  | 0.5793              | 0.596                           | 0.2947              |
| 2     | 0.228                  | 0.7046              | 0.518                           | 0.3155              |
| 3     | 0.166                  | 0.7002              | 0.446                           | 0.3154              |
| 4     | 0.220                  | 0.7997              | 0.475                           | 0.3274              |
| 5     | 0.174                  | 0.8164              | 0.421                           | 0.3304              |
| 6     | 0.135                  | 0.7697              | 0.431                           | 0.3385              |
| 7     | 0.106                  | 0.8652              | 0.412                           | 0.3446              |

|           |        |        |       |        |
|-----------|--------|--------|-------|--------|
| <b>8</b>  | 0.102  | 0.8839 | 0.472 | 0.3604 |
| <b>9</b>  | 0.103  | 0.8662 | 0.462 | 0.3600 |
| <b>10</b> | 0.0689 | 0.8927 | 0.427 | 0.3615 |

從結果中可以看到，模型在訓練過程中 loss 較高，而在 validation data 的 accuracy 只有 **0.3615**，這可能是因為三位數與混合型樣本佔比高，導致模型在學習過程中主要學習到長序列結構與較大數值範圍的特徵，最終應用在只包含兩位數 validation data 泛化能力差。

### C. 訓練資料含 20% 錯誤答案 (label noise)

| Epoch     | 正確資料集         |                     | 20% 錯誤答案資料集   |                     |
|-----------|---------------|---------------------|---------------|---------------------|
|           | Training Loss | Validation Accuracy | Training Loss | Validation Accuracy |
| <b>1</b>  | 0.335         | 0.5793              | 0.997         | 0.3822              |
| <b>2</b>  | 0.228         | 0.7046              | 0.954         | 0.4507              |
| <b>3</b>  | 0.166         | 0.7002              | 0.959         | 0.4952              |
| <b>4</b>  | 0.220         | 0.7997              | 0.938         | 0.5212              |
| <b>5</b>  | 0.174         | 0.8164              | 1.030         | 0.5084              |
| <b>6</b>  | 0.135         | 0.7697              | 0.933         | 0.5317              |
| <b>7</b>  | 0.106         | 0.8652              | 1.010         | 0.5657              |
| <b>8</b>  | 0.102         | 0.8839              | 0.981         | 0.5621              |
| <b>9</b>  | 0.103         | 0.8662              | 0.973         | 0.5738              |
| <b>10</b> | 0.0689        | 0.8927              | 0.806         | 0.5855              |

在使用含有 20% 錯誤答案的訓練資料時，loss 明顯比前面的實作結果還高

( 0.9~1.0)，且 Validation accuracy 最終僅達到 0.58，代表資料中的錯誤答案

會干擾模型學習正確的算式邏輯。其中 LSTM 在 teacher forcing 訓練下會被迫

學習錯誤關係(混入錯誤標籤)，這也是導致整體 loss 收斂速度變慢、accuracy 下降的原因。

**D. 是否使用 gradient clipping (訓練穩定性)**

以下表格未使用 Gradient Clipping 的訓練結果：

| Epoch | Training Loss | Validation Accuracy |
|-------|---------------|---------------------|
| 1     | 0.573         | 0.3417              |
| 2     | 0.555         | 0.3608              |
| 3     | 0.528         | 0.4276              |
| 4     | 0.639         | 0.4090              |
| 5     | 0.592         | 0.3828              |
| 6     | 0.534         | 0.4287              |
| 7     | 0.447         | 0.4281              |
| 8     | 0.689         | 0.4214              |
| 9     | 0.554         | 0.4280              |
| 10    | 0.434         | 0.4678              |

未使用 gradient clipping 情況下 LSTM 模型，在訓練中 loss 整體呈下降趨勢，

但在中間有兩個 epoch（第 4、8 epoch）出現 Loss 暴衝現象，顯示訓練存在

較不穩定問題。在 Validation accuracy 雖有提升，但在第 6-9epoch 收斂效果

差，相較於前面實作而言收斂較不穩定。

整體而言，移除 gradient clipping 會降低訓練的穩定性，並可能導致後期收斂不

佳，此實驗近一步驗證 gradient clipping 重要性。

## E. Seq2Seq Encoder–Decoder + input reversal

參考 Sequence to Sequence Learning with Neural Networks (2014) 提出的 input reversal，觀察其在算式答案生成任務是否能改善對齊與訓練穩定性。

做法：將輸入算式字元序列整段反轉（如 "12+34=" → "=43+21"），以 2-layer LSTM Encoder 讀取反轉輸入，Decoder 逐步生成答案（共享 embedding）。

結果：

| Epoch | Train Loss | Validation Accuracy |
|-------|------------|---------------------|
| 1     | 0.253      | 0.0781              |
| 2     | 0.182      | 0.0810              |
| 3     | 0.0582     | 0.0819              |
| 4     | 0.0766     | 0.0809              |
| 5     | 0.0489     | 0.0863              |
| 6     | 0.0680     | 0.0993              |
| 7     | 0.111      | 0.1031              |
| 8     | 0.0664     | 0.1106              |
| 9     | 0.138      | 0.1069              |
| 10    | 0.0584     | <b>0.1157</b>       |

training loss 由 0.253 降至 0.058，訓練穩定；但 validation exact-match accuracy 僅提升至 0.1157。

討論：雖然 Encoder – Decoder 架構可正常收斂，但「整段反轉」會破壞算式的運算結構（運算子與括號的局部關係、以及 operand 的自然排列），使模型更難學到正確的邏輯映射。因此 input reversal 在翻譯任務有效的假設（縮短對

應距離) 不一定適用於運算生成。

#### 四、結語

本專案驗證字元層級序列模型可用於算式答案生成：以 **2-layer LSTM** 為基準模型，在驗證集上可達 **0.8927** 的 **Exact Match accuracy**。

此外，透過五項實驗發現：

1. 不同模型記憶機制對於生成品質影響
2. 訓練/驗證分佈不一致會顯著降低泛化能力
3. **Label noise** 在 **teacher forcing** 下會削弱學習效果
4. **Gradient clipping** 對 **RNN** 訓練穩定性至關重要
5. 「整段反轉」可能破壞算式的結構與語義對齊，導致模型難以學到正確映射。

引用：

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.