

Multi-Output Transformer for Relatedness & Entailment

一、研究概述

本專案使用句子配對 (Sentence A / Sentence B) 資料，模型輸入為兩句話，輸出同時包含語意相似度分數與蘊含關係分類。

主要做法是建立一個 **BERT-base-uncased** 多輸出基線模型：共享同一個 BERT encoder，上接兩個線性輸出頭（語意相似度分析、蘊含關係分類）。

在此基線之上，會設計多組對照實驗：

A. BERT-base-uncased 多輸出基線模型 vs 兩個 BERT 單任務分開訓練的

差異性分析

B. 不同預訓練/架構差異對句對任務的影響

(BERT-base vs RoBERTa-base vs GPT-2)

C. 類別不平衡 vs 任務衝突診斷 (Weighted CE Ablation)

二、研究流程

1. SemEval 2014 Task 1 資料介紹

資料是「兩句話一組」的形式。每筆樣本附上兩個標註：

- 標註 1 (回歸任務) - 語意相關度分數 (**relatedness_score**) : 介於 1–5 的連續數值
- 標註 2 (分類任務) - 文本蘊含關係 (**entailment_judgement**) : 三分類
 - 0 : NEUTRAL
 - 1 : ENTAILMENT
 - 2 : CONTRADICTION

資料已切分為訓練集(4500 筆)、驗證集 (4500 筆) 與測試集 (4927 筆)。

2. 模型訓練超參數設定

BERT-base-uncased multi-output : 以 bert-base-uncased 作為共享 encoder，接兩個 task head

訓練超參數如下：(BERT / RoBERTa / GPT-2 皆採相同設定)

- Learning rate : **2e-5**
- Epochs : **20**
- Train batch size : **16**
- Validation batch size : **16**
- Optimizer : **Adam**

3. 實驗組別設計

(A) BERT-base-uncased 多輸出基線模型 vs 兩個 BERT 單任務分開訓練的差異性分析

異性分析

建立兩個獨立的 BERT 模型，分別只訓練回歸任務、分類任務，，並比較與 multi-output 的效能差異。

(B) 不同預訓練/架構差異對句對任務的影響 (BERT-base vs RoBERTa-base vs GPT-2)

	BERT-base	RoBERTa-base	GPT-2
架構	Encoder	Encoder	Decoder
注意力方向	雙向（看前後文）	雙向（看前後文）	單向（看左側上下文）
預訓練目標	MLM（填空） → 偏理解	MLM（更強訓練策略） → 偏理解	Next-token LM → 偏生成
句對建模直覺	原生支援 sentence-pair	原生支援 sentence-pair	需額外設計，不如 Encoder 直接
此任務適配	句對理解、適合回歸+ 分類	同為句對理解，通常 更強	偏生成式，做句對判 別通常較差

(C) 類別不平衡 vs 任務衝突診斷 (Weighted CE Ablation)

在 (A) 實驗中發現，相比於單任務模型，multi-output 結果可觀察到「分類任務受益、回歸任務略差」的不對稱現象，因此我提出兩個可能原因：

1. entailment 三分類存在類別不平衡
2. multi-output 造成任務梯度衝突 (**task conflict**)

訓練集分佈統計也可發現類別不平衡問題：Neutral 2536 / Entailment 1299 / Contradiction 665。

因此我對分類 head 的 CrossEntropyLoss 加上逆頻率權重：[1.00, 1.95, 3.81]，

其餘模型架構與超參數完全不變，重新訓練後在 test 評估。

- 若分類顯著提升 → 類別不平衡可能是主因
- 若回歸/分類同步下降或整體變差 → 更支持 **task conflict** 為主要問題

三、結果討論

A. BERT-base-uncased 多輸出 vs 兩個 BERT 單任務

	multi-output	Regression ONLY model	Classification ONLY model
Test Pearson Correlation	0.8900	0.8945	X

Test Accuracy	0.8910	X	0.8567
----------------------	--------	---	--------

分析結果說明：

對於迴歸任務， multi-output 模型的相關係數 (0.8900) 稍微低於單獨訓練的迴歸模型 (0.8945)，但是對於分類任務， multi-output 模型的準確率 (0.8910) 顯著高於單獨訓練的分類模型 (0.8567)。迴歸任務是一個較廣泛的語意任務，它強迫共享的 BERT 層去學習更全面的語意表徵。分類任務是一個更困難的邏輯任務，當分類任務自己訓練時，從結果可推論其實學得不太好，但是在 multi-output 模型中，分類任務額外享受到了迴歸任務所學到的豐富語意特徵，有輔助資訊因此效能提升到 0.8910 。

但是這兩個任務可能也有輕微的任務衝突，在迴歸任務上會希望模型忽略一些反義詞，去看他們的主題相關，但在分類任務會希望模型關注一些反義詞，才能有效判斷邏輯是屬於哪一類標籤，因此在 multi-output 模型結果中，迴歸任務的效能看似被分類任務受到了輕微的干擾。

B. BERT-base vs RoBERTa-base vs GPT-2

	BERT-base	RoBERTa-base	GPT-2
Test Pearson Correlation	0.8900	0.9063	0.7074
Test Accuracy	0.8910	0.8947	0.7668

在相同資料集與相同訓練設定下，三個模型在測試集表現呈現明顯差異：

RoBERTa-base 最佳、GPT-2 最差。RoBERTa-base 在 Test Pearson / Accuracy 分別達 0.9063 / 0.8947，均高於 BERT-base 的 0.8900 / 0.8910；有趣的是，訓練結束時 BERT-base 的平均 loss 更低 (0.0580) 而 RoBERTa-base loss 較高 (0.1042) 但泛化表現更好，顯示 **RoBERTa** 可能因預訓練策略（如 **dynamic masking**、移除 **NSP**、更充分的預訓練）而具備較強的泛化能力、較不易對訓練資料過擬合。相較之下，GPT-2 的 Test Pearson / Accuracy 僅 0.7074 / 0.7668，且訓練平均 loss 也顯著較高 (1.7380)。這與方法中所預測結果一致：

BERT/RoBERTa 為 **Encoder** 雙向注意力、以 **MLM** 為主偏語意理解，更適合本專案的句對理解；**GPT-2** 為 **Decoder** 單向注意力、以 **next-token** 生成為目標，較難同時利用句子兩側上下文形成完整的雙向語意表徵，因此表現明顯不如 Encoder-based 模型。

C. 類別不平衡 vs 任務衝突診斷 (Weighted CE Ablation)

	BERT-base (原始權重 1:1)	Weighted Loss
Test Pearson Correlation	0.8900	0.8778
Test Accuracy	0.8910	0.8502

從結果來看，任務衝突才是主要限制因素。導入加權損失後，模型效能全面下降。權重放大後造成的效能下降，凸顯了多任務間的梯度干擾。

當「矛盾」類別的損失被放大至 3.81 倍時，分類任務對否定語與邏輯線索的梯度被過度強化，而回歸任務則試圖忽略否定詞以維持語義平滑，二者反而破壞模型收斂。

從比較中也可以發現，原始的多輸出模型實際上已達到兩個任務間的最佳折衷，強化單一任務權重反而破壞了這個平衡，導致整體表現下降。

四、結語

本專案以 BERT-base multi-output 雙頭模型為基線，同步進行相關度回歸與蘊含三分類，並透過三組實驗驗證多輸出學習與模型差異。

1. **multi-output** 對分類有明顯增益 ($0.8910 > 0.8567$)，但回歸略受干擾 ($0.8900 < 0.8945$)。
2. **Encoder-based** 更適合句對理解：RoBERTa 最佳 ($0.9063/0.8947$)，BERT 次之 ($0.8900/0.8910$)，GPT-2 最差 ($0.7074/0.7668$)。
3. **Weighted CE** 反而讓整體下降 ($0.8778/0.8502$)，顯示主要瓶頸更像是 **task conflict** 而非單純類別不平衡。

此外，我抓出兩任務誤差最大的前 10 筆資料進行錯誤分析顯示模型常過度依賴詞彙重疊而忽略關鍵反義詞，分類端也會因語意階層關係（如 **tree $\subset$ plant**）掌握不足而誤判；回歸端則可能被複雜或誤導性句構混淆。未來可透過（1）針

對反義詞/矛盾關係的資料增強，（2）採用更強的預訓練模型（如 **RoBERTa-large**、**DeBERTa**），以及（3）調整分類 **loss** 權重以降低過度預測 **NEUTRAL** 的傾向，進一步提升模型的泛化能力。