

Word-Embeddings-Exploration: Word Analogy Task

一、研究概述

本研究利用 **Google Analogy Dataset** 評估 **Word2Vec (Skip-gram)** 模型在不同變數下的語義捕捉能力。

實驗核心會針對三大面向的差異，去做結果比較與討論：

- A. 用不同抽樣比例的 **Wikipedia** 訓練模型的差異性分析
- B. 訓練語料庫的差異性分析（對比知識導向的 **Wikipedia** 與時事導向的 **News Crawl**）
- C. 類比推理演算法的效能評估（對比傳統的 **3CosAdd** 與優化的 **3CosMul**），藉此深入探討模型在語義（**Semantic**）與語法（**Syntactic**）任務上的表現差異。

二、研究流程

本研究採用 **Word2Vec (Skip-gram)** 架構作為核心模型，詳細訓練流程如下：

1. 資料預處理：將文本轉為小寫並去除標點符號，過濾純數字但保留英數混合單字，並移除缺乏語義資訊的停用詞。
2. 模型訓練與參數設定：
 - **vector_size=300**：每個詞用 300 個數字來表示

- **window=5**：模型會依照前後 5 個詞來學習詞的關係
- **min_count=2**：出現次數少於 2 的詞會被忽略，希望保留更多低頻詞
- **sg=1**：以 Skip-gram 訓練，希望模型能更好地學到低頻詞的語義關係
- **negative=5**：用 5 個隨機的「假例子」來幫助訓練
- **epochs=10**：訓練 10 輪

3. 實驗組別設計

本研究設計了三組對照實驗：

A. 不同抽樣比例 Wikipedia 訓練模型差異分析：針對 Wikipedia 進行

5%、10%、20% 的抽樣，探討 5%~20% 語料規模對語義學習的邊際收益。

B. 訓練語料庫比較實驗：

	Wikipedia 語料庫 (Wiki20)	News Crawl 語料庫 (News25)
數據規模	20% 抽樣 (約 6.7 億 Tokens)	25% 抽樣 (約 7.2 億 Tokens)
主題差異	涵蓋廣泛的百科知識，特別是地名、國家、專有名詞豐富	內容會更加貼近日常或新聞語境，語法結構多變化，但是較少

		涉及罕見專有名詞
結構差異	文章篇幅長、句子結構複雜，資訊密集	短句子、對話式或新聞敘事為主

- C. **類比演算法實作**：針對詞類比任務實作 **3CosAdd** 與 **3CosMul** 兩種 Scoring 方式，評估其在捕捉詞法規則上的差異。

說明：

3CosAdd 方法雖然簡單直觀，但容易受到單一向量主導，導致比例或詞形規則的關係不穩定。在 Sousa et al. (2020) 提到 **3CosMul** 在處理類比任務時往往能更好地捕捉比例關係，特別是在語法型子題上表現更佳，因此我將這兩個類比任務套用在以 **20% Wikipedia** 作為訓練的 Word2Vec 模型做比較，同樣使用 Google Analogy 測試集，分別以 **3CosAdd** 與 **3CosMul** 評估任務準確率，並比較兩者差異。

2

4. 測試資料集：Google Word Analogy Dataset

本研究採用 Google 推出的 **Word Analogy Dataset** 作為模型效能的評估基準。

該資料集包含 **19,544** 個測試條目，其核心任務是透過給定的前三個單字 (A, B,

C) ，預測第四個單字 D，以驗證模型是否捕捉到「A 之於 B 等同於 C 之於 D」的關係。

測試任務分兩大範疇：

- 語義關係 (Semantic, 5 個子類別)：測試模型對世界知識與概念邏輯的理解，如地名或社會關係。
- 語法關係 (Syntactic, 9 個子類別)：測試模型對語言形態變化的捕捉能力，如形容詞轉副詞或時態變化。

三、結果討論

A. 不同抽樣比例下所訓練模型在測試集表現（使用相同前處理與模型超參數）

Sub-Category	5% Accuracy	10% Accuracy	20% Accuracy
Semantic	71.58 %	75.43%	76.01%
capital-common-countries	95.65 %	95.85%	95.06%
capital-world	84.95 %	90.14%	90.45%
currency	3.23 %	6.12%	9.24%
city-in-state	69.88 %	71.67%	70.73%
family	53.16 %	60.47%	67.79%
Syntactic	48.20 %	52.08%	57.15%
gram1-adjective-to-adverb	14.62 %	20.77%	28.53%
gram2-opposite	15.02 %	19.46%	25.25%

gram3-comparative	61.79 %	67.57%	74.17%
gram4-superlative	22.55 %	27.63%	37.08%
gram5-present-participle	37.41 %	44.03%	47.82%
gram6-nationality- adjective	88.12 %	89.37%	89.49%
gram7-past-tense	52.44 %	51.92%	52.88%
gram8-plural	61.71 %	62.29%	72.82%
gram9-plural-verbs	41.15 %	45.86%	54.94%

分析結果說明：

1. 高頻且規律性強（首都/國籍）：在 5%時已具備良好準確率，隨資料量增加的進步有限。
2. 語料敏感度高（家族、比較級/複數/時態）：表現隨抽樣比例逐漸成長。
主因是 Semantic 任務中的長尾詞彙出現機率增加，且 Syntactic 任務的形態規則學習更趨完整。
3. 高變化且不規則（貨幣、反義詞、形容詞轉副詞）：雖隨資料量上升而進步，但在 20%比例下仍受限。此類任務規律性低，僅靠「共現關係」較難習得穩定的對應向量。

B. 不同訓練語料庫下所訓練模型在測試集表現（使用相同前處理與模型超參數）

Category / Sub-Category	Wiki20 (20% 抽樣, 671,986,897 tokens)	News25 (25% 抽樣, 721739576 tokens)
Semantic	76.01%	67.56%
capital-common-countries	95.06%	91.11%
capital-world	90.45%	79.60%
currency	9.24%	8.43%
city-in-state	70.73%	63.40%
family	67.79%	57.91%
Syntactic	57.15%	66.65%
gram1-adjective-to-adverb	28.53%	30.14%
gram2-opposite	25.25%	32.39%
gram3-comparative	74.17%	87.24%
gram4-superlative	37.08%	69.70%
gram5-present-participle	47.82%	72.63%
gram6-nationality-adjective	89.49%	89.37%
gram7-past-tense	52.88%	67.56%
gram8-plural	72.82%	66.89%
gram9-plural-verbs	54.94%	53.79%

結果分析：

- Semantic 準確率在 Wikipedia 較高：
 - Wikipedia 以百科全書式知識為主，涵蓋大量專有名詞與定義。這使得模型在語意層級的關聯性極強，對於知識性概念與專業領域能建構出精確的語意空間。

- 雜訊來源：由於 Wikipedia 收錄了極其廣泛的條目，結果中有時會混入較冷門的人物、地名或極專業的學術術語（如 king 的相似詞出現多位歷史君主名：harthacnut, prajadhipok）。
- Syntactic 準確率在 News Crawl corpus 較高：
 - 新聞語料偏重事件報導與語言使用，因此文句較為生活化，包含大量動詞時態、比較級、最高級、複數形式，使模型在 Syntactic 子類別上的表現更佳。
 - 來源於事件報導，文句多符合現代語言邏輯與生活化表達，包含頻繁的動詞時態、比較級與複數形式變化，因此模型在處理語法子類別時表現更佳。
 - 在醫療與商業領域，其關聯詞更貼近日常認知（如 apple 連結到 blackberry, homepod；king 連結到 queen, monarch），展現出強大的現實連結力。
 - 雜訊來源：可能受限於網路抓取語料的品質，結果中偶爾會出現拼字錯誤（如 university 的相似詞中混入 univeristy 等錯字）。

C. 不同類比演算法（以 20% Wikipedia 作為訓練的 Word2Vec 模型為基礎）

Word2Vec (3CosAdd): 66.31%
Word2Vec (3CosMul): 67.29%

	SubCategory	3CosAdd	3CosMul	Δ
13	: gram9-plural-verbs	54.942529	62.873563	7.931034
8	: gram4-superlative	37.076649	43.939394	6.862745
11	: gram7-past-tense	52.884615	57.371795	4.487179
2	: currency	9.557945	11.589008	2.031063
9	: gram5-present-participle	47.821970	48.768939	0.946970
7	: gram3-comparative	74.174174	74.624625	0.450450
0	: capital-common-countries	95.059289	95.454545	0.395257
1	: capital-world	90.450928	90.340407	-0.110522
10	: gram6-nationality-adjective	89.493433	89.305816	-0.187617
3	: city-in-state	70.733685	70.085124	-0.648561
5	: gram1-adjective-to-adverb	30.430108	29.569892	-0.860215
12	: gram8-plural	72.822823	71.771772	-1.051051
4	: family	81.666667	80.476190	-1.190476
6	: gram2-opposite	25.246305	24.014778	-1.231527

整體準確率由 **66.31%** 提升至 **67.29%**，提升幅度不大，但在 Syntactic

子類別（如 gram9-plural-verbs +7.93%、gram4-superlative +6.86%、

gram7-past-tense +4.49%）顯著優於 3CosAdd；而在 Semantic 子類別

（如 family, gram2-opposite）則差異有限甚至略有下降。

- 算法特性：3CosMul 在「詞形變化」與「比例邏輯」具備優勢，與前人研究 (Sousa et al., 2020) 觀察一致。
- 核心價值：證明類比任務可透過「後處理 scoring 技巧」優化，特別是對語法規則的掌握。

四、結語

本研究經由三組對照實驗，針對 Word2Vec 在類比推理任務上的表現總結如下：

- 語料規模的結果提升與侷限性：增加 Wikipedia 抽樣比例能穩定提升模型表現，特別是針對長尾詞彙（如：家族關係）與形態規則（如：比

較級、複數形式) 的學習效果顯著。然而，對於高頻且具規律性的任務

(如：國家與首都)，5%語料已能達到預期表現，後續增量的結果提升相對有限。

- 語料庫領域特性的互補：語料庫的本質深刻影響詞向量的應用領域。

Wikipedia 其百科知識結構，在語義關聯 (Semantic) 與專業學術領域較有優勢；而 **News Crawl** 因貼近生活的語言特性與豐富的動詞變化，在語法結構 (Syntactic) 與現代商業詞彙的關聯性上表現更佳。

- 演算法優化對後處理的重要性：透過 **3CosMul** 代替傳統 3CosAdd，能在不增加訓練成本的情況下，透過優化比例邏輯與詞形變化的運算，顯著提升模型在語法子題上的準確率（如複數與時態任務），印證了「後處理技巧」在嵌入模型應用中的關鍵作用。

引用：

Sousa, T., Fernandes, P., & Alves, A. (2020). *Exploring different methods for solving analogies with Portuguese word embeddings*. In R. Moreno-Díaz, F. Pichler, & A. Quesada-Arencibia (Eds.), **Proceedings of the 9th Symposium on Languages, Applications and Technologies (SLATE 2020)** (Vol. 82, pp. 9:1–9:9). Schloss Dagstuhl–Leibniz-Zentrum für Informatik.
<https://doi.org/10.4230/OASlcs.SLATE.2020.9>